

Atividade registro semana 13 ia

Nome: Arthur Saraiva de França 3B.

Site utilizado: OpenAI Tokenizer

Parte 1 – O básico da tokenização:

1. Frase: "Olá, mundo!"
Tokens: [89191, 11, 10225, 0]

Observação:

A vírgula foi representada como um token separado. O espaço antes da palavra "mundo" ficou junto da palavra, formando um único token.

2. Frase: "Qual é a capital do Brasil?"
Tokens: [16752, 1212, 261, 9029, 621, 15278, 30]

Observação:

Nem todas as palavras se tornaram um único token. O tokenizador divide o texto da forma que considera mais eficiente com base nos padrões aprendidos durante o treinamento.

Parte 2 – O desafio do idioma e das palavras raras

1. Teste de idioma:

"Let's go!"
Tokens: [58369, 810, 0]
Quantidade: 3 tokens

"Vamos lá!"
Tokens: [104186, 16243, 0]
Quantidade: 3 tokens

Análise:

As duas frases utilizaram a mesma quantidade de tokens. Isso mostra que frases curtas podem ter eficiência semelhante em idiomas diferentes.

2. Teste de palavra rara:

"anticonstitucionalissimamente"
Tokens: [493, 3679, 5028, 39284, 123329, 3444]
Quantidade: 6 tokens

Análise:

A palavra foi dividida em várias partes. O algoritmo BPE faz isso porque palavras raras geralmente não aparecem com frequência suficiente para serem armazenadas como um único token.

3. Teste de internetês

"pq vc n vem?"

Tokens: [124147, 40337, 297, 34209, 30]

Quantidade: 5 tokens

"Por que você não vem?"

Tokens: [12429, 661, 7888, 3671, 34209, 30]

Quantidade: 6 tokens

Análise:

A versão abreviada utilizou menos tokens. Isso mostra que abreviações podem reduzir o custo de processamento, embora possam diminuir a clareza do texto.

Parte 3 – Implicações práticas

1. Custo:

Traduzir para inglês pode ser mais econômico, pois normalmente o inglês utiliza menos tokens que o português. Assim, é possível processar mais texto gastando menos.

2. Comportamento:

Quando uma palavra é dividida em vários tokens, o modelo precisa interpretar cada parte separadamente. Isso pode dificultar a compreensão completa do significado da palavra.

3. Limite de contexto:

Como o português costuma usar mais tokens que o inglês, é possível enviar menos texto em português antes de atingir o limite máximo de tokens do modelo.

Perguntas de Consolidação:

1. Qual foi a tokenização mais inesperada que você encontrou?

A tokenização mais inesperada foi a palavra "anticonstitucionalissimamente", pois imaginei que seria um único token, mas ela foi dividida em vários pedaços menores.

2. Agora que você entende como o BPE funciona, você consegue pensar em uma "palavra-armadilha"?

Um exemplo de palavra-armadilha seria "abc你好123مرحباxyz", pois mistura diferentes idiomas e caracteres, tornando a tokenização menos eficiente.

3. Como a compreensão da tokenização muda sua abordagem ao escrever prompts?

Compreender a tokenização ajuda a escrever prompts mais claros e organizados. Evitar excesso de gírias e abreviações pode facilitar a interpretação do modelo e melhorar a qualidade das respostas.